

생성형 AI 기반 채용은 공정한가?

LLM 지원자 평가에서 나타나는 편향과 공정성 분석



2023315644 허주환, 2026310630 이유빈

01

주제 선정 배경

생성형 AI와 LLM
채용 과정의 의사결정
지원 도구 가능성↑

많은 지원자를
빠르고 일관된 기준으로
평가 가능



평가자의
주관적 판단이나 편견↓
기대

인간이 생성한 대규모 데이터 학습
→ 성별, 인종, 직업 등에 대한
편향 학습 가능성 有

→ 오히려 편견을 기반한 평가가
자동화되거나 증폭

채용은 개인의 취업 기회와 직접적으로 연결되는 고위험 의사결정 영역이므로
생성형 AI가 지원자를 얼마나 공정하게 평가하는지 검토할 필요가 있다.

02

연구질문 설정

01

LLM 기반 지원자 평가에서 집단 간
평가 격차가 실제로 나타나는가?

02

편향의 정도와 방향은
GPT, Claude, Gemini, Llama 등
모델에 따라 다른가?

03

최신 LLM으로 발전하면서
이러한 편향은 감소하고 있는가?

04

생성형 AI를 채용에 활용하기 위해서
어떠한 공정성 검증과 제도적 장치가
필요한가?

동일한 능력의
지원자를
LLM은
동일하게
평가하는가?

03

핵심 논문 선정

PNAS Nexus(2025)

여러 LLM이 지원자에게 0~100점의 평가점수를 부여한 데이터

성별과 인종이 결합되었을 때 평가점수가 달라지는지 볼 수 있음

5개 모델 회귀 및 4개 모델 공통 표본 비교

Rozado(2026)

AI에게 두 지원자 중 누구를 선택할 것인지 묻는 실험


성별에 따른 선택 차이, 후보자 제시 순서에 따른 영향,
모델별 선택 경향 등을 볼 수 있음

22개 모델, 70개 직업군 대상 15,399개 Pair 복원 분석

평가점수와 실제 선택 행동은 서로 다른 공정성 문제이므로 하나의 Fairness Score로 통합하지 않습니다.

04

데이터 분석 과정



01

공개 데이터·코드 직접 확보
SHA-256 hash로 원본파일 확인

02

결측·중복·인코딩·비표준 선택값을 표시
missing을 채우거나 행을 임의 삭제X

03

각 행의 원본 위치를 pair, 회귀 표본,
공통 표본 membership까지 추적
Rozado는 15,399개 pair를 복원

04

PNAS 회귀를 Python으로 다시 구현
계수 30/30일치 여부와 Holm 보정 결과 확인


05

스크립트가 표·추정치·그림을 자동 생성
결과에서 원자료까지 역추적 가능한 구조 남김

05

PNAS:성별·인종 교차집단별 점수 격차의 방향이 달랐다

비교집단 (VS White Male)	관측된 점수 격차 방향	통계적 유의성 (Holm 보정)
White Female	다소 높은 점수(+)	유의함 ($p < 0.05$)
Black Female	높은 점수(+)	유의함 ($p < 0.05$)
Black Male	낮은 점수(-)	대부분 유의함 (Llama 제외)



05

PNAS:성별·인종 교차집단별 점수 격차의 방향이 달랐다

공통 표본 모델 간 직접 비교

- 동일한 지원자 집합을 평가해도 모델마다 특정 집단에 대한 점수 격차의 크기와 방향이 다름.
- 18개의 모델 간 비교 중 12개에서 통계적으로 뚜렷한 차이가 확인됨.

단순화의 오류

- 결과가 단순히 '여성에게 불리' 또는 'Black 지원자에게 불리' X
- 성별과 인종의 조합에 따라 평가 방향이 달라지는 교차적 편향이 핵심


크기와 의미의 구분

- PNAS에서는 집단 간 점수 차이가 통계적으로 유의하게 나타남
- 그러나 대부분의 차이는 0-100점 중 1점 미만
- 차이가 존재함과 실제 채용 결과를 크게 바꾼다는 것을 구분해야함

결과 분석

06

- 동일한 이력서 (경력·자격 조건 고정)에서
남녀 이름을 각각 붙여 AI의 선택 비교
- 22개의 모든 모델에서
여성 이름 선택 비율이 50% 이상으로 나타남
- 이는 단순한 무작위 선택을 넘어선
일관된 경향성을 보여줌



06

Rozado: 같은 이력에서 이름만 바꿔 선택 비교

Fixed Masking

원래 Male → Candidate A
원래 Female → Candidate B
성별과 라벨 대응이 고정됨

Counterbalanced

- 성별과 A/B 라벨 대응을
서로 교차하여 배정함
- 라벨 선호 효과를 분리

- Fixed 에서는 A/B 라벨 선호와 원래 성별이 얽혀 정확한 진단이 어려움
- Counterbalanced 에서도 A 선택 비율이 50%와 다른 모델은 12개
- 이름을 지우는 것 ≠ 라벨 영향을 없애는 것

07 Rozado: 이름 가려도 모든 편향이 사라지진 않는다

진단 지표(조건)	모델별 선택 비율 범위	유의미한 모델 수 (Holm $p < 0.05$)
Name/Order: 첫 번째 후보 선택	41.2% - 81.4%	18/22
Fixed Masking: Candidate A 선택	47.2% - 59.1%	13/22
Fixed Masking: 첫 번째 후보 선택	43.5% - 88.3%	17/22
Counterbalanced: Candidate A 선택	46.6% - 58.7%	12/22
Counterbalanced: 첫 번째 후보 선택	43.1% - 88.3%	17/22
Counterbalanced: 원래 Female 할당 선택	49.2% - 51.9%	0/22

Counterbalanced masking에서 원래 Female 할당 선택은 50% 근처로 모였지만
A/B 라벨 및 첫 후보 선택의 비대칭성은 여전히 강하게 남았다.
따라서 성별 역매칭 지표 하나의 변화만으로 채용 시스템 전체의 공정성이 확보됐다고 결론 내릴 수 없다.

08

향후 데이터 활용 및 정책 제언 방향



Fairness Audit

채용에 AI를 도입하기 전 성별·인종 등 주요 집단별 평가 결과를 비교하여 편향 여부를 지속적으로 검증한다.



Human Oversight

AI가 최종 채용 여부 단독 결정X
인간의 의사결정을 보조하는 형태로 활용



지속적인 모니터링

LLM의 종류와 버전에 따라 편향의 방향과 크기가 달라질 수 있으므로 모델 변경 및 업데이트 이후에도 공정성을 재평가한다.



설명 및 이의제기 절차

지원자가 AI 평가 결과에 대해 설명 요구나 이의를 제기할 수 있는 절차를 마련한다.

09

토론해볼 거리

인간 면접관에게 편견이 존재해서 AI를 도입했는데, AI 역시 편향을 보인다면 어느 쪽의 판단을 더 신뢰해야 하는가?

서로 다른 편향을 보이는 여러 LLM 중 하나를 기업이 선택하여 채용에 사용했다면, 그 결과에 대한 책임은 누구에게 있는가?



감사합니다